

# Estimación Puntual

# Introducción

- En **Probabilidades** se conocían todos los datos sobre la v.a.
  - Ejemplo:  $X \sim B(25, 0.1)$  y podíamos calcular  $P(X=5)$ .
- En **Estadística** desconocemos las características de  $X$  total o parcialmente.
  - Ejemplo: sabemos que  $X$  tiene distribución binomial pero **desconocemos  $p$**  y a partir de una muestra de 25 artículos trataremos de hallar información sobre  $p$ .

# Inferencia Estadística

- El campo de la ***inferencia estadística*** está formado por los métodos utilizados para tomar decisiones o para obtener conclusiones sobre el o los parámetros de una población a partir de la información contenida en una muestra.
- La inferencia estadística puede dividirse en dos grandes áreas:
  - ❑ Estimación de Parámetros.
  - ❑ Pruebas de hipótesis.

# Estimación Puntual


- Dado un parámetro de interés, como una media poblacional  $\mu$  o una proporción  $p$  de la población, el objetivo de la estimación puntual es usar una muestra para calcular un número que representa, en cierto sentido, una buena estimación del valor real del parámetro.
- El número resultante se llama ***estimación puntual***.
- La estimación se realiza a través de algún ***estadístico*** (ej: media muestral).

# Ejemplo 7.1

- Suponga que el parámetro de interés es  $\mu$ , el tiempo de vida útil promedio de baterías de cierto tipo.
- Ej: muestra de  $n=3$  baterías. Para c/u se indica el tiempo de vida útil observado (horas)

$x_1=5.0$ ,  $x_2 = 6.4$  y  $x_3 = 5.9$ . El valor calculado del tiempo de vida útil promedio de la muestra es

$$\bar{x} = 5.77$$



Podría considerarse este valor como la mejor estimación de  $\mu$  a partir de la información de la muestra.

# Estimador Puntual

- Cuando un estadístico se utiliza para estimar un parámetro desconocido se lo llama ***estimador puntual***.
- Es habitual simbolizar en forma genérica a un parámetro con la letra  $\theta$  y al estadístico que se utiliza como estimador puntual de  $\theta$ , simbolizarlo con  $\hat{\theta}$ .
- Al medir la muestra aleatoria se obtienen  $x_1, x_2, \dots, x_n$  y entonces ***el valor que toma  $\hat{\theta}$  es***

$$\hat{\theta} = h(x_1, x_2, \dots, x_n)$$

y se denomina ***estimación puntual de  $\theta$***

# Estimadores usuales

- Sea  $X_1, X_2, \dots, X_n$  una muestra aleatoria de una v.a.  $X$  donde  $E(X)=\mu$  y  $V(X)=\sigma^2$ .
- Si se desconoce  $\mu$ , un estadístico que se utiliza para estimar ese parámetro es la **media o promedio muestral**

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

# Estimadores usuales

- Sea  $X_1, X_2, \dots, X_n$  una muestra aleatoria de una v.a.  $X$  donde  $E(X)=\mu$  y  $V(X)=\sigma^2$ .
- Si se desconoce  $\sigma^2$ , un estadístico que se utiliza para estimar ese parámetro es la **varianza muestral**

$$S^2 = \frac{1}{\underbrace{n-1}} \sum_{i=1}^n (X_i - \bar{X})^2$$

Luego veremos porque utiliza  $(n-1)$  en lugar de  $n$



# Estimadores usuales

- Si se busca estimar la proporción  $p$  de objetos de una población que cumplen una determinada característica, el estimador puntual sería

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i$$

donde  $X_i$  vale 1 si la  $i$ -ésima observación tiene la característica de interés y 0 si no, para  $i=1,2,\dots, n$ .

# Más de un estimador

- Puede ocurrir que se tenga más de un estimador para un parámetro.
- Ejemplo: Para estimar el valor de  $\mu$  puede utilizarse la media muestral o también la semisuma entre  $X_1$  y  $X_n$

$$\hat{\mu} = \frac{X_1 + X_n}{2}$$

- En estos casos necesitamos de algún ***criterio para decidir cuál es mejor estimador*** de  $\mu$

# Criterios para evaluar estimadores

- En una situación ideal, se podría encontrar un estimador  $\hat{\theta}$  para el cual siempre se cumpla que  $\hat{\theta} = \theta$ .
- Sin embargo,  $\hat{\theta}$  es una función de las  $X_i$  muestrales y por lo tanto, una v.a.

$$\therefore \hat{\theta} = \theta + \underbrace{\text{error de estimacion}}$$

Lo que se necesita es un estimador que tenga las propiedades de *insesgamiento* y *varianza mínima*.

# Estimador insesgado

- Se dice que un estimador puntual  $\hat{\Theta}$  es ***estimador insesgado*** del parámetro  $\theta$  si

$$E(\hat{\Theta}) = \theta$$

cualquiera sea el valor verdadero de  $\theta$ .

- **Sesgo del estimador** :  $E(\hat{\Theta}) - \theta$
- Note que si el estimador es insesgado, su sesgo es cero.

## Ejemplo 7.2

- Sea  $X_1, X_2, \dots, X_n$  una muestra aleatoria de una v.a.  $X$  donde  $E(X)=\mu$  y  $V(X)=\sigma^2$ .
- Veamos si la media muestral

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

es un estimador insesgado de  $\mu$ . Debemos ver que

$$E(\bar{X}) = \mu$$

## Ejemplo 7.2

$$E(\overline{X}) \stackrel{?}{=} \mu$$

- Usando la prop.de linealidad de la esperanza

$$E(\overline{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} E\left(\sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i)$$

- Por tratarse de componentes de una muestra aleatoria

$$E(X_i) = E(X) = \mu \quad \forall i = 1, 2, \dots, n$$

- Luego

$$E(\overline{X}) = \frac{1}{n} n\mu = \mu$$

## Ejemplo 7.3

- Sea  $X_1, X_2, \dots, X_n$  una muestra aleatoria de una v.a.  $X$  donde  $E(X)=\mu$  y  $V(X)=\sigma^2$ .
- Veamos si la varianza muestral

$$\hat{\sigma}^2 = S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

es un estimador insesgado de  $\sigma^2$ . Debemos ver que

$$E(S^2) = \sigma^2$$

## Ejemplo 7.3

$$\hat{\sigma}^2 = S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

$$\begin{aligned} E(S^2) &= E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) \\ &= \frac{1}{n-1} E\left(\sum_{i=1}^n (X_i - \bar{X})^2\right) \end{aligned}$$

Reescribamos la suma sumando y restando  $\mu$   
y desarrollando el cuadrado



## Ejemplo 7.3

$$\begin{aligned}\sum_{i=1}^n (X_i - \bar{X})^2 &= \sum_{i=1}^n ([X_i - \mu] + [\mu - \bar{X}])^2 = \\&= \sum_{i=1}^n ([X_i - \mu]^2 + 2[X_i - \mu][\mu - \bar{X}] + [\mu - \bar{X}]^2) = \\&= \sum_{i=1}^n [X_i - \mu]^2 + \sum_{i=1}^n 2[X_i - \mu][\mu - \bar{X}] + \sum_{i=1}^n [\mu - \bar{X}]^2 =\end{aligned}$$

## Ejemplo 7.3

$$= \sum_{i=1}^n [X_i - \mu]^2 + \sum_{i=1}^n 2[X_i - \mu][\mu - \bar{X}] + \sum_{i=1}^n [\mu - \bar{X}]^2 =$$

$$= \sum_{i=1}^n [X_i - \mu]^2 + 2[\mu - \bar{X}] \underbrace{\sum_{i=1}^n [X_i - \mu]}_{\substack{\uparrow \\ \sum_{i=1}^n [X_i - \mu] = \sum_{i=1}^n X_i - n\mu = n(\bar{X} - \mu)}} + n[\mu - \bar{X}]^2 =$$

$$\sum_{i=1}^n [X_i - \mu] = \sum_{i=1}^n X_i - n\mu = n(\bar{X} - \mu)$$

## Ejemplo 7.3

$$= \sum_{i=1}^n [X_i - \mu]^2 + \sum_{i=1}^n 2[X_i - \mu][\mu - \bar{X}] + \sum_{i=1}^n [\mu - \bar{X}]^2 =$$

$$= \sum_{i=1}^n [X_i - \mu]^2 + 2[\mu - \bar{X}] \sum_{i=1}^n [X_i - \mu] + n[\mu - \bar{X}]^2 =$$

$$= \sum_{i=1}^n [X_i - \mu]^2 + 2[\mu - \bar{X}]n[\bar{X} - \mu] + n[\mu - \bar{X}]^2 =$$

$$= \sum_{i=1}^n [X_i - \mu]^2 - 2n[\mu - \bar{X}]^2 + n[\mu - \bar{X}]^2 =$$

$$\sum_{i=1}^n [X_i - \bar{X}]^2 = \sum_{i=1}^n [X_i - \mu]^2 - 2n[\mu - \bar{X}]^2 + n[\mu - \bar{X}]^2 =$$

## ■ Entonces

$$\begin{aligned} E(S^2) &= \frac{1}{n-1} E\left(\sum_{i=1}^n [X_i - \mu]^2 - n[\mu - \bar{X}]^2\right) \\ &= \frac{1}{n-1} \left(\sum_{i=1}^n E[X_i - \mu]^2 - nE[\mu - \bar{X}]^2\right) \\ &= \frac{1}{n-1} \left(\sum_{i=1}^n V(X_i) - nE[\mu - \bar{X}]^2\right) \end{aligned}$$

$$\begin{aligned}
 E(S^2) &= \frac{1}{n-1} \left( \sum_{i=1}^n V(X_i) - nE[\mu - \bar{X}]^2 \right) \\
 &= \frac{1}{n-1} \left( \sum_{i=1}^n V(X_i) - nE[\bar{X} - \mu]^2 \right) \\
 &= \frac{1}{n-1} \left( \sum_{i=1}^n V(X_i) - nE[\bar{X} - E(\bar{X})]^2 \right) \\
 &= \frac{1}{n-1} \left( \sum_{i=1}^n V(X_i) - nV(\bar{X}) \right)
 \end{aligned}$$

$$E(S^2) = \frac{1}{n-1} \left( \sum_{i=1}^n V(X_i) - nV(\bar{X}) \right)$$

■ Usando

$$V(X_i) = V(X) = \sigma^2 \quad \forall i = 1, 2, \dots, n$$

y que

$$V(\bar{X}) = \frac{\sigma^2}{n}$$

$$E(S^2) = \frac{1}{n-1} \left( n\sigma^2 - n \frac{\sigma^2}{n} \right) \quad \Rightarrow \quad E(S^2) = \sigma^2$$

## Ejemplo 7.4

- La definición de varianza estándar es un estimador sesgado de la varianza

$$E\left[\frac{(n-1)S^2}{n}\right] = \frac{n-1}{n} E(S^2) = \frac{n-1}{n} \sigma^2$$

Por ser negativo, este estimador tiende a subestimar  $\sigma^2$

**Resumen** Sea  $X_1, X_2, \dots, X_n$  una muestra aleatoria de una v.a.  $X$  donde  $E(X)=\mu$  y  $V(X)=\sigma^2$

$\bar{X}$	$\frac{1}{n} \sum_{i=1}^n X_i$	$E(\bar{X}) = \mu$ $V(\bar{X}) = \frac{\sigma^2}{n}$
$S^2$	$\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$	$E(S^2) = \sigma^2$
$S_{EMV}^2$	$\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$	$E(S_{EMV}^2) = \frac{n-1}{n} \sigma^2$

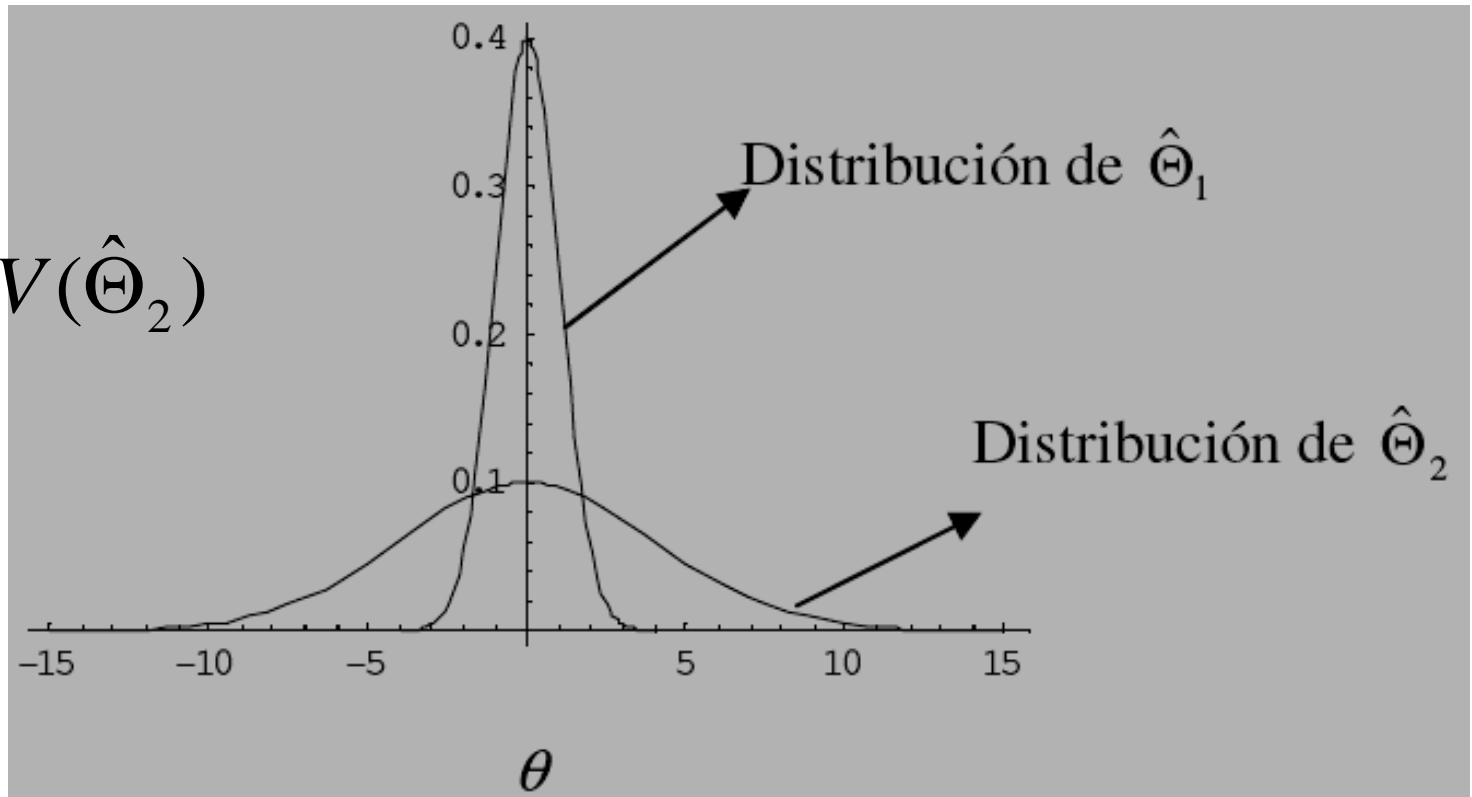


# Criterios para evaluar estimadores

- En ocasiones hay más de un estimador insesgado de un parámetro  $\theta$
- Por lo tanto necesitamos un método para seleccionar un estimador entre varios estimadores insesgados.
  - Varianza
  - Error Cuadrático medio

# Varianza de un estimador

$$V(\hat{\Theta}_1) < V(\hat{\Theta}_2)$$



Si tenemos dos estimadores insesgados  
debemos elegir el de menor varianza

## Ejemplo 7.5

- Sea  $X_1, X_2, \dots, X_n$  una muestra aleatoria de una v.a.  $X$  donde  $E(X)=\mu$  y  $V(X)=\sigma^2$
- Para estimar el parámetro  $\mu$  podría utilizarse

$$\hat{\mu}_1 = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$



Ya vimos que es  
insesgado

$$\hat{\mu}_2 = \frac{X_1 + X_2}{2}$$



Veamos si es  
insesgado

## Ejemplo 7.5

$$E(\hat{\mu}_2) = \mu$$

$$\begin{aligned} E(\hat{\mu}_2) &= E\left(\frac{X_1 + X_2}{2}\right) = \frac{1}{2}(E(X_1) + E(X_2)) \\ &= \frac{1}{2}(\mu + \mu) = \frac{1}{2}2\mu = \mu \end{aligned}$$

Por lo tanto  $\mu_2$  también es insesgado

Entonces ¿Cuál de los dos estimadores es mejor?

## Ejemplo 7.5

- Calculamos la varianza de cada uno utilizando las propiedades de la varianza.

$$V(\bar{X}) = V\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} V\left(\sum_{i=1}^n X_i\right)$$

$$\stackrel{\uparrow}{=} \frac{1}{n^2} \sum_{i=1}^n V(X_i) \stackrel{\uparrow}{=} \frac{1}{n^2} n \sigma^2 = \frac{\sigma^2}{n}$$

Las  $X_i$  son v.a.  
independientes

Todas las  $X_i$  tienen la  
misma varianza

## Ejemplo 7.5

$$V(\bar{X}) = \frac{\sigma^2}{n}$$

$$\begin{aligned} V(\hat{\mu}_2) &= V\left(\frac{X_1 + X_2}{2}\right) = \frac{1}{4} (V(X_1) + V(X_2)) \\ &= \frac{1}{4} (\sigma^2 + \sigma^2) = \frac{\sigma^2}{2} \end{aligned}$$

Si  $n > 2$  el mejor estimador es  $\hat{\mu}_1$  porque

$$V(\hat{\mu}_1) < V(\hat{\mu}_2)$$

# Criterios para evaluar estimadores

- Supongamos ahora que  $\hat{\Theta}_1$  y  $\hat{\Theta}_2$  son dos estimadores de un parámetro  $\theta$  y ***alguno de ellos no es insesgado.***
- A veces es necesario utilizar un estimador sesgado. En esos casos puede ser importante el ***error cuadrático medio del estimador.***

# Error cuadrático medio (ECM)

- El error cuadrático medio de un estimador  $\hat{\Theta}$  de un parámetro  $\theta$  está definido como

$$ECM(\hat{\Theta}) = E\left[(\hat{\Theta} - \theta)^2\right]$$

- También puede escribirse como

$$ECM(\hat{\Theta}) = V(\hat{\Theta}) + \left(b(\hat{\Theta})\right)^2$$

- siendo  $b(\hat{\Theta}) = E(\hat{\Theta}) - \theta$

El ECM es un  
criterio para  
comparar  
estimadores



# Eficiencia relativa

- Si  $\hat{\Theta}_1$  y  $\hat{\Theta}_2$  son dos estimadores de un parámetro  $\theta$ , la eficiencia relativa de  $\hat{\Theta}_2$  con respecto a  $\hat{\Theta}_1$  se define como

$$\frac{ECM(\hat{\Theta}_1)}{ECM(\hat{\Theta}_2)}$$


- Si es un valor menor que 1,  $\hat{\Theta}_1$  tiene menor ECM que  $\hat{\Theta}_2$  y **por lo tanto  $\hat{\Theta}_1$  es más eficiente que  $\hat{\Theta}_2$**

# Criterios para evaluar estimadores

- Si  $\hat{\Theta}$  es un estimador insesgado de  $\theta$  entonces

$$ECM(\hat{\Theta}) = V(\hat{\Theta})$$

- En el ECM se consideran la varianza y el sesgo del estimador.
- Si  $\hat{\Theta}_1$  y  $\hat{\Theta}_2$  son dos estimadores de  $\theta$  tales que  $E(\hat{\Theta}_1) = \theta$ ;  $E(\hat{\Theta}_2) \neq \theta$  y  $V(\hat{\Theta}_2) < V(\hat{\Theta}_1)$ , habría que calcular el ECM de cada uno y tomar el menor



- Habría que calcular el ECM de cada uno, y elegir el que tenga el menor valor. Aunque  $\hat{\Theta}_2$  sea sesgado, al tener menor varianza podría llegar a tomar valores mas cercanos al verdadero parámetro  $\hat{\Theta}_1$ .

## Ejemplo 7.6

- Sean  $\hat{\Theta}_1$ ,  $\hat{\Theta}_2$  y  $\hat{\Theta}_3$  tres estimadores de un parámetro  $\theta$  tales que

$$E(\hat{\Theta}_1) = E(\hat{\Theta}_2) = \theta; E(\hat{\Theta}_3) \neq \theta$$

$$V(\hat{\Theta}_1) = 10, V(\hat{\Theta}_2) = 6, E((\hat{\Theta}_3 - \theta)^2) = 4$$

Haga una comparación de estos estimadores.  
¿Cuál prefiere y por qué?

## Ejemplo 7.6

- Calculamos el ECM de cada estimador

$$ECM(\hat{\Theta}_1) = V(\hat{\Theta}_1) = 10$$

$$ECM(\hat{\Theta}_2) = V(\hat{\Theta}_2) = 6$$

$$ECM(\hat{\Theta}_3) = E((\hat{\Theta}_3 - \Theta)^2) = 4$$

El mejor estimador es  $\hat{\Theta}_3$  porque tiene menor error cuadrático medio.

# Consistencia de estimadores puntuales

- Sea  $\hat{\Theta}_n$  un estimador del parámetro  $\theta$  basado en una muestra aleatoria  $(X_1, X_2, \dots, X_n)$ , si

$$\lim_{n \rightarrow \infty} E(\hat{\Theta}_n) = \theta \quad \text{y} \quad \lim_{n \rightarrow \infty} V(\hat{\Theta}_n) = 0$$

entonces  $\hat{\Theta}_n$  es un **estimador consistente** de  $\theta$

## Ejemplo 7.7

- La media muestral es un estimador consistente?
- Sabemos que

$$a) E(\bar{X}) = \mu = E(X) \quad \forall n \quad \leftarrow$$

$$b) V(\bar{X}) = \frac{\sigma^2}{n} = \frac{V(X)}{n} \quad \forall n \quad \leftarrow$$

Vemos que tiende a cero cuando  $n \rightarrow \infty$  ;  
**por lo tanto el estimador es consistente**

## Ejercicio 7.1

- Dados los siguientes estimadores para la media muestral

$$\hat{\mu}_1 = \frac{x_1 + x_n}{2}$$

$$\hat{\mu}_2 = \frac{x_1 + x_2 + x_3}{3}$$

- Calcule para cada uno: sesgo, varianza y ECM.
- Son estimadores consistentes?
- Utilice la eficiencia relativa para indicar cual de los dos debería ser utilizado.



## Ejercicio 7.1

- Sesgo del estimador :  $E(\hat{\Theta}) - \theta$

$$\hat{\mu}_1 = \frac{x_1 + x_n}{2}$$

$$E(\hat{\mu}_1) = E\left(\frac{x_1 + x_n}{2}\right) = \frac{1}{2} E(x_1 + x_n)$$

## Ejercicio 7.1

- Sesgo del estimador :  $E(\hat{\Theta}) - \theta$

$$\hat{\mu}_1 = \frac{x_1 + x_n}{2}$$

$$E(\hat{\mu}_1) = \mu$$
$$\therefore \text{sesgo} = 0$$

$$E(\hat{\mu}_1) = \frac{1}{2} E(x_1 + x_n) = \frac{1}{2} = \frac{1}{2} * 2 * \mu = \mu$$

# Ejercicio 7.1

## ■ Varianza

$$\begin{aligned} V(\hat{\mu}_1) &= V\left(\frac{x_1 + x_n}{2}\right) = \frac{1}{4} V(x_1 + x_n) \\ &= \frac{1}{4} [V(x_1) + V(x_n)] = \frac{1}{4} * 2 * V(x) \end{aligned}$$

$$V(\hat{\mu}_1) = V(X) / 2$$

## Ejercicio 7.1

$$ECM(\hat{\mu}_1) = V(\hat{\mu}_1) + (b(\hat{\mu}_1))^2$$

- Por ser un estimador insesgado

$$ECM(\hat{\mu}_1) = V(\hat{\mu}_1) = V(X) / 2$$

## Ejercicio 7.1

- De la misma forma puede verse que

- $\hat{\mu}_2$  también es insesgado

- $V(\hat{\mu}_2) = V(X) / 3$

- $ECM(\hat{\mu}_2) = V(\hat{\mu}_2) = V(X) / 3$

- Eficiencia relativa

$$\frac{ECM(\hat{\mu}_1)}{ECM(\hat{\mu}_2)} = \frac{V(X)}{2} : \frac{V(X)}{3} = \frac{3}{2} > 1$$

Elegimos

$\hat{\mu}_2$

# Métodos de estimación puntual

- Se analizan dos métodos constructivos para obtener estimadores puntuales
  - Método de momentos
  - Método de máxima verosimilitud
    - Los estimadores obtenidos de esta forma suelen ser más eficientes pero requieren más cálculo.

# Método de momentos

- La idea básica es igualar ciertas características muestrales, como la media, con los valores esperados correspondientes.
- Esto da lugar a un conjunto de ecuaciones cuya solución, para valores de parámetros desconocidos, producen los estimadores.

# Método de Momentos

- Sean  $X_1, \dots, X_n$  una muestra aleatoria de una función de probabilidad  $f(x)$ .
- Se definen

- El **k-ésimo momento de la distribución**  $f(x)$  como

$$\mu_k = E(X^k) \quad k=1, 2, 3, \dots$$

- El **k-ésimo momento muestral** como

$$M_k = \frac{1}{n} \sum_{i=1}^n X_i^k \quad k=1, 2, 3, \dots$$



# Método de Momentos

- Sean  $X_1, X_2, \dots, X_n$  una muestra aleatoria de una distribución con función de probabilidad  $p(x_i, \theta_1, \theta_2, \dots, \theta_r)$  si  $X$  es discreta o  $f(x_i, \theta_1, \theta_2, \dots, \theta_r)$  si  $X$  es continua, donde  $\theta_1, \theta_2, \dots, \theta_r$  son parámetros que se desconocen.
- Entonces los estimadores de momento  $\hat{\Theta}_1, \hat{\Theta}_2, \dots, \hat{\Theta}_r$  se obtienen igualando los primeros  $r$  momentos muestrales con los primeros  $r$  momentos de la distribución y resolviendo para  $\theta_1, \theta_2, \dots, \theta_r$

# Método de Momentos

- Sean  $X_1, X_2, \dots, X_n$  una muestra aleatoria de una distribución cuya función de probabilidad tiene parámetros  $\theta_1, \theta_2, \dots, \theta_r$  desconocidos, deben resolverse la siguientes ecuaciones para dichos parámetros

$$E(X^k) = \frac{1}{n} \sum_{i=1}^n X_i^k \quad k=1, 2, \dots, r$$

$$\mu_k = E(X^k) = \begin{cases} \sum_{x_i \in R_X} x_i^k \cdot p(x_i, \theta_1, \theta_2, \dots, \theta_r) & \text{(discreta)} \\ \int_{-\infty}^{\infty} x_i^k \cdot f(x_i, \theta_1, \theta_2, \dots, \theta_r) & \text{(continua)} \end{cases}$$

## Ejemplo 7.8

- Sea  $(X_1, X_2, \dots, X_n)$  una muestra aleatoria de tamaño  $n$  de una v.a. donde  $X \sim U[0, \theta]$ , con  $\theta$  desconocido. Hallar el estimador de  $\theta$  por el método de los momentos.

$\therefore$  debe igualarse el 1er. momento muestral con el 1er. momento de la distribución

$$E(X) = \frac{1}{n} \sum_{i=1}^n X_i \quad \therefore \quad E(X) = \bar{X}$$

## Ejemplo 7.8

$$E(X) = \frac{0 + \theta}{2} = \frac{\theta}{2} \Rightarrow \frac{\theta}{2} = \bar{X} \Rightarrow \hat{\Theta} = 2\bar{X}$$

- Verifique que este estimador es consistente

$$E(\hat{\Theta}) = E(2\bar{X}) = 2E(\bar{X}) = 2\frac{\theta}{2} = \theta$$

$$V(\hat{\Theta}) = V(2\bar{X}) = 4V(\bar{X}) = 4\frac{(\theta - 0)^2}{12n} = \frac{\theta^2}{3n} \xrightarrow{n \rightarrow \infty} 0$$

## Ejemplo 7.9

- Estimar por el método de los momentos los parámetros  $\mu$  y  $\sigma^2$  de una distribución normal.
- Como son dos parámetros utilizaremos los dos primeros momentos de la distribución normal, que están dados por:

$$\mu_1 = E(X) = \mu$$

$$\mu_2 = E(X^2) = \sigma^2 + \mu^2$$

## Ejemplo 7.9

- Luego, igualando los dos primeros momentos de la distribución normal con sus respectivos momentos muestrales tenemos que:

$$\mu_1 = M_1 \Rightarrow \mu = \bar{X} \Rightarrow \hat{\mu} = \bar{X}$$

$$\mu_2 = M_2 \Rightarrow \sigma^2 + \mu^2 = \frac{1}{n} \sum_{i=1}^n x_i^2$$

$$\therefore \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$$

# Ejercicio de la práctica

- Sea  $t_1, t_2, \dots, t_n$  una muestra aleatoria de  $n$  observaciones de una variable aleatoria discreta  $T$ , con función de frecuencia de probabilidad  $p(t)$  ; ( $0 < \theta < 1$ )

$t$	0	1	2
$p(t)$	$\theta^2$	$2 \theta(1 - \theta)$	$(1 - \theta)^2$

- Halle un estimador de  $\theta$  utilizando el método de los momentos.

# Ejercicio de la práctica

- Para calcular un estimador de  $\theta$  utilizando el método de los momentos hay que igualar el primer momento de la distribución,  $E(T)$ , con el primer momento muestral (la media muestral)

$$\underbrace{E(T)}_{\uparrow} = \frac{\sum_{i=1}^n x_i}{n}$$

Usemos la tabla de la distribución de probabilidad de  $T$  para calcular  $E(T)$



# Ejercicio de la práctica

- Dada  $p(t)$ , calcular  $E(T)$

t	0	1	2
p(t)	$\theta^2$	$2 \theta(1 - \theta)$	$(1 - \theta)^2$

- $$E(T) = 0 * \theta^2 + 1 * (2 * \theta * (1 - \theta)) + 2 * (1 - \theta)^2$$

$$= 2 \theta - 2 \theta^2 + 2 - 4 \theta + 2 \theta^2$$

- $$E(T) = -2 \theta + 2$$

Luego igualamos  $E(T)$  al primer momento muestral

# Ejercicio de la práctica

- Para calcular un estimador de  $\theta$  utilizando el método de los momentos hay que igualar el primer momento de la distribución,  $E(T)$ , con el primer momento muestral (la media muestral)

$$E(T) = \frac{\sum_{i=1}^n x_i}{n} \quad \therefore \quad -2\theta + 2 = \frac{\sum_{i=1}^n x_i}{n} \quad \therefore$$

$$\theta = \frac{1}{2} \left( 2 - \frac{\sum_{i=1}^n x_i}{n} \right) \quad \therefore \quad \hat{\Theta} = 1 - \frac{\bar{X}}{2}$$

## Ejercicio 7.2

- El tiempo de falla  $T$  de una componente tiene una distribución exponencial con parámetro  $\lambda$ .  $T \sim \text{Exp}(\lambda)$ , es decir la fdp es

$$f(t; \lambda) = \begin{cases} \lambda e^{-\lambda t} & t \geq 0 \\ 0 & \text{si no} \end{cases}$$

- Recordemos que  $E(T) = 1/\lambda$        $V(T) = 1/\lambda^2$
- Calculemos el estimador por el método de momentos del parámetro  $\lambda$  para una muestra de tamaño  $n$ .

## Ejercicio 7.2

$$E(T) = 1/\lambda$$

- Debe igualarse

The diagram illustrates the relationship between the theoretical first moment of a distribution and the sample first moment. It features two dashed red boxes at the top, each containing a term of an equation. The left box contains  $E(T)$  and the right box contains  $\frac{\sum_{i=1}^n t_i}{n}$ . Below these boxes are two more dashed red boxes. The left box contains the text "1er. momento de la distribución" and the right box contains "1er. momento muestral". A double-headed yellow arrow connects the left top box to the left bottom box, and another double-headed yellow arrow connects the right top box to the right bottom box.

$$E(T) = \frac{\sum_{i=1}^n t_i}{n}$$

1er. momento de la distribución

1er. momento muestral

## Ejercicio 7.2

$$E(T) = 1/\lambda$$

- Debe igualarse

$$\frac{1}{\lambda} = \frac{\sum_{i=1}^n t_i}{n}$$

$$\therefore \lambda = n / \sum_{i=1}^n t_i \quad \Rightarrow \quad \hat{\lambda} = \frac{1}{\overline{T}}$$

# Método de Máxima Verosimilitud

- Sea  $X$  es una v.a. discreta con fdp  $p(x, \theta)$ , donde  $\theta$  es un parámetro desconocido.
- Sean  $x_1, x_2, \dots, x_n$  los valores observados de una muestra aleatoria de tamaño  $n$ .
- Se define la **función de verosimilitud como la función de distribución conjunta de las observaciones**

$$\begin{aligned} L(x_1, x_2, \dots, x_n, \theta) &= P(X_1 = x_1)P(X_2 = x_2) \dots P(X_n = x_n) \\ &= p(x_1, \theta)p(x_2, \theta) \dots p(x_n, \theta) \end{aligned}$$

# Método de Máxima Verosimilitud

- Sea  $X$  es una v.a. continua con fdp  $f(x, \theta)$ , donde  $\theta$  es un parámetro desconocido.
- Sean  $x_1, x_2, \dots, x_n$  los valores observados de una muestra aleatoria de tamaño  $n$ .
- Se define la **función de verosimilitud como la función de distribución conjunta de las observaciones**

$$L(x_1, x_2, \dots, x_n, \theta) = f(x_1, \theta) f(x_2, \theta) \dots f(x_n, \theta)$$

# Método de Máxima Verosimilitud

## ■ La función de Verosimilitud

$$L(x_1, x_2, \dots, x_n, \theta) = p(x_1, \theta) p(x_2, \theta) \dots p(x_n, \theta)$$

$$L(x_1, x_2, \dots, x_n, \theta) = f(x_1, \theta) f(x_2, \theta) \dots f(x_n, \theta)$$

es una función de  $\theta$ .

**El estimador de máxima verosimilitud (EMV)**  
de  $\theta$  es aquel valor de  $\theta$  que maximiza la función  
de verosimilitud



# Ejemplo 7.10

- Sea  $(X_1, X_2, \dots, X_n)$  una muestra aleatoria de tamaño  $n$  de una v.a.  $X \sim B(1, p)$ .
- Por ejemplo, se eligen al azar  $n$  objetos de una línea de producción, y cada uno se clasifica como defectuoso (en cuyo caso  $x_i=1$ ) o no defectuoso (en cuyo caso  $x_i=0$ ).
- Entonces  $p=P(X_i=1)$ , es decir es la verdadera proporción de objetos defectuosos en la producción total.
- Queremos hallar el EMV de  $p$ .

## Ejemplo 7.10

- La función de verosimilitud será

$$L(x_1, x_2, \dots, x_n, \theta) = p(x_1, \theta) p(x_2, \theta) \dots p(x_n, \theta) = \\ \left[ p^{x_1} (1-p)^{1-x_1} \right] \left[ p^{x_2} (1-p)^{1-x_2} \right] \dots \left[ p^{x_n} (1-p)^{1-x_n} \right]$$

- Esto puede escribirse

$$L(x_1, x_2, \dots, x_n, \theta) = p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i}$$

## Ejemplo 7.10

- Aplicando logaritmo natural de L

$$\ln(L(x_1, x_2, \dots, x_n, \theta)) = \left( \sum_{i=1}^n x_i \right) \ln p + \left( n - \sum_{i=1}^n x_i \right) \ln(1 - p)$$

- Derivando respecto de p e igualando a cero

$$\frac{\partial \ln(L(x_1, x_2, \dots, x_n, \theta))}{\partial p} = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1 - p} = 0$$

$$\frac{\partial \ln(L(x_1, x_2, \dots, x_n, \theta))}{\partial p} = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = 0$$

$$\frac{\sum_{i=1}^n x_i}{p} = \frac{n - \sum_{i=1}^n x_i}{1-p} \Rightarrow (1-p) \sum_{i=1}^n x_i = p \left( n - \sum_{i=1}^n x_i \right)$$

$$\sum_{i=1}^n x_i - p \sum_{i=1}^n x_i = pn - p \sum_{i=1}^n x_i \Rightarrow \sum_{i=1}^n x_i = pn$$

$$p = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \quad \leftarrow \quad \begin{array}{|l} \text{la pro} \\ \text{de la} \end{array} \quad \hat{p} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad \begin{array}{|l} \text{sos} \end{array}$$

## Ejemplo 7.11

- El tiempo de falla  $T$  de una componente tiene una distribución exponencial con parámetro  $\lambda$ .  $T \sim \text{Exp}(\lambda)$ , es decir la fdp es

$$f(t; \lambda) = \begin{cases} \lambda e^{-\lambda t} & t \geq 0 \\ 0 & \text{si no} \end{cases}$$

- Recordemos que  $E(T) = \frac{1}{\lambda}$        $V(T) = \frac{1}{\lambda^2}$
- Calculemos el EMV del parámetro  $\lambda$  para una muestra de tamaño  $n$ .

## Ejemplo 7.11

- La función de verosimilitud será

$$\begin{aligned} L(t_1, t_2, \dots, t_n; \lambda) &= f(t_1; \lambda) f(t_2; \lambda) \dots f(t_n; \lambda) = \\ &= [\lambda e^{-\lambda t_1}] [\lambda e^{-\lambda t_2}] \dots [\lambda e^{-\lambda t_n}] \end{aligned}$$

- Esto puede escribirse

$$L(t_1, t_2, \dots, t_n; \lambda) = (\lambda)^n e^{-\lambda \sum_{i=1}^n t_i}$$

## Ejemplo 7.11

- Aplicando logaritmo natural de L

$$\ln(L(t_1, t_2, \dots, t_n; \lambda)) = \ln\left(\lambda^n e^{-\lambda \sum_{i=1}^n t_i}\right) = n \ln(\lambda) - \lambda \sum_{i=1}^n t_i$$

- Derivando respecto de  $\lambda$  e igualando a cero

$$\frac{\partial \ln(L(t_1, t_2, \dots, t_n; \lambda))}{\partial \lambda} = n \frac{1}{\lambda} - \sum_{i=1}^n t_i = 0$$

$$\lambda = \frac{n}{\sum_{i=1}^n t_i} = \frac{1}{\bar{t}}$$



$$\hat{\lambda} = \frac{n}{\sum_{i=1}^n T_i} = \frac{1}{\bar{T}}$$

# Método de máxima verosimilitud

## ■ Características

- Algunas veces, resulta difícil maximizar la función de verosimilitud debido a que la ecuación obtenida a partir de

$$\frac{\partial L(\theta)}{\partial \theta} = 0$$

no resulta fácil de resolver.

- También puede ocurrir que los métodos de cálculo para maximizar  $L(\theta)$  *no sean aplicables*



## Ejemplo 7.12

- Sea  $(X_1, X_2, \dots, X_n)$  una muestra aleatoria de tamaño  $n$  de una v.a.  $X \sim U(0, \theta)$ , con  $\theta$  desconocido. Hallar el estimador de  $\theta$  por el método de máxima verosimilitud.
- La *fdp* de  $X$  es

$$f(x) = \begin{cases} \frac{1}{\theta} & 0 < x < \theta \\ 0 & \text{si no} \end{cases}$$

## Ejemplo 7.12

- La función de verosimilitud es

$$L(x_1, x_2, \dots, x_n; \theta) = \begin{cases} \frac{1}{\theta^n} & \text{si } \max_i(x_i) < \theta \\ 0 & \text{si no} \end{cases}$$


- Si derivamos con respecto a  $\theta$  obtenemos

$$\frac{d}{d\theta} \theta^{-n} = -\frac{n}{\theta^{n+1}}$$

Siempre es  
menor que cero

## Ejemplo 7.12

- La función de máxima verosimilitud es una función decreciente para todos los  $\theta > \max_i(x_i)$



- Vemos que donde la función tiene el máximo hay una discontinuidad no evitable. Por lo tanto

$$\hat{\Theta} = \max_i(x_i)$$

# Método de máxima verosimilitud

- El método de máxima verosimilitud puede emplearse en el caso donde hay más de un parámetro desconocido para estimar.
- En ese caso la función de verosimilitud es una función de varias variables.

$$L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k)$$

# Método de máxima verosimilitud

■ Si

$$L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k)$$

los estimadores de máxima verosimilitud

$\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$  se obtienen al plantear (si existen las derivadas parciales) y resolver el sistema de k ecuaciones con k incógnitas

$$\theta_1, \theta_2, \dots, \theta_k$$

$$\frac{d}{d\theta_i} L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k) = 0 \quad i=1,2,\dots,k$$

## Ejercicio 7.3

- Encontrar el estimador de máxima verosimilitud para el parámetro  $p$  de una distribución geométrica para una muestra de tamaño  $n$ .

- Recuerde que si  $X \sim G(p)$

$$p(X = k) = (1 - p)^{k-1} p \quad k=1, 2, \dots$$

## Ejercicio 7.3

- La función de verosimilitud será

$$\begin{aligned} L(x_1, x_2, \dots, x_n; \lambda) &= p(x_1; p) p(x_2; p) \dots p(x_n; p) = \\ &= \left[ (1-p)^{x_1-1} p \right] \left[ (1-p)^{x_2-1} p \right] \dots \left[ (1-p)^{x_n-1} p \right] \end{aligned}$$

- Esto puede escribirse

$$L(x_1, x_2, \dots, x_n; p) = (1-p)^{\sum_{i=1}^n (x_i - 1)} p^n$$

## Ejercicio 7.3

- Aplicando logaritmo natural de L

$$\begin{aligned}\ln(L(x_1, x_2, \dots, x_n; p)) &= \ln \left( (1-p)^{\sum_{i=1}^n (x_i - 1)} p^n \right) \\ &= \ln \left( (1-p)^{\sum_{i=1}^n (x_i - 1)} \right) + \ln(p^n) \\ &= \sum_{i=1}^n (x_i - 1) \ln(1-p) + n \ln(p)\end{aligned}$$



## Ejercicio 7.3

- Por lo tanto,

$$\ln(L(x_1, \dots, x_n; p)) = \sum_{i=1}^n (x_i - 1) \ln(1 - p) + n \ln(p)$$

- Derivando respecto de  $\lambda$  e igualando a cero

$$\frac{\partial \ln(L(x_1, \dots, x_n; p))}{\partial p} = - \frac{\sum_{i=1}^n (x_i - 1)}{1 - p} + \frac{n}{p} = 0$$

- Por lo tanto,

$$\frac{n}{p} = \frac{\sum_{i=1}^n (x_i - 1)}{1 - p}$$

## Ejercicio 7.3

■ Por lo tanto,

$$\frac{n}{p} = \frac{\sum_{i=1}^n (x_i - 1)}{1 - p} \quad \Rightarrow \quad (1 - p)n = p \sum_{i=1}^n (x_i - 1)$$

$$n - np = p \sum_{i=1}^n x_i - p \sum_{i=1}^n 1 \quad \Rightarrow \quad n - np = p \sum_{i=1}^n x_i - np$$

$$n = p \sum_{i=1}^n x_i \quad \Rightarrow \quad \frac{n}{\sum_{i=1}^n x_i} = p \quad \Rightarrow \quad \hat{p} = \frac{1}{\bar{X}}$$

# Propiedades de los EMV

## ■ Propiedad 1

Los EMV pueden ser **sesgados**, pero en general si  $\hat{\Theta}$  es el EMV de un parámetro  $\theta$  basado en una muestra de tamaño  $n$ , entonces

$$\lim_{n \rightarrow \infty} E(\hat{\Theta}) = \theta$$

es decir son **asintóticamente insesgados**

# Propiedades de los EMV

## ■ Propiedad 2

- Bajo condiciones bastantes generales se puede probar que los EMV son ***asintóticamente consistentes***

## ■ Propiedad 3

- Bajo condiciones bastantes generales se puede probar que los EMV ***asintóticamente tienen varianza mínima***

# Propiedades de los EMV

## ■ Propiedad 4

- Los EMV cumplen la ***propiedad de invarianza***.
- Es decir que si  $\hat{\theta}$  es un EMV de un parámetro  $\theta$ , el EMV de  $g(\theta)$  es  $g(\hat{\theta})$ , si  $g(x)$  es una función inyectiva.

A cada valor de la imagen le corresponde un único valor en el dominio

## Ejemplo 7.14

- En el Ejemplo 7.11 teníamos una v.a.  $T$  con distribución exponencial,  $T \sim \text{Exp}(\lambda)$ . Si queremos el EMV de la varianza poblacional, podemos calcularlo recordando que

$$V(T) = 1/\lambda^2 \quad \text{es decir que} \quad V(T) = g(\lambda) = 1/\lambda^2$$

- Vimos que

$$\hat{\lambda} = \frac{n}{\sum_{i=1}^n T_i} = \frac{1}{\bar{T}} \quad \text{por lo tanto}$$

$$\sigma^2 = \frac{1}{\hat{\lambda}^2}$$

# Resumen

- Estimador Puntual
  - Estimadores Usuales
  - Criterios
    - Insesgamiento
    - Varianza Mínima
    - ECM
    - Eficiencia Relativa
- Métodos de estimación puntual
    - Método de Momentos
    - Método de máxima verosimilitud
      - Propiedades